



专题二：无约束优化

唐冲 教授

工程抗震研究所

建设工程学院

无约束优化问题

$$\min_{\mathbf{x} \in \mathbf{R}^n} f(\mathbf{x})$$

1. 最优解类型与条件
2. 最速下降法(Steepest descent method)
3. 牛顿法(Newton method)
4. 共轭梯度法(Conjugate gradient method)
5. 拟牛顿法(Quasi-Newton method)

1. 全局最优

定义1: 设 $f: S \rightarrow \mathbb{R}$ 是定义在集合 $S \subseteq \mathbb{R}^n$ 上的函数

- ① 对于任意 $x \in S$ 有 $f(x) \geq f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的全局最小值点
- ② 对于任意 $x^* \neq x \in S$ 有 $f(x) > f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的严格全局最小值点
- ③ 对于任意 $x \in S$ 有 $f(x) \leq f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的全局最大值点
- ④ 对于任意 $x^* \neq x \in S$ 有 $f(x) < f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的严格全局最大值点


其中集合 S 称为可行集, 任意一点 $x \in S$ 称为可行解

2. 局部最优

定义2: 设 $f: S \rightarrow \mathbb{R}$ 是定义在集合 $S \subseteq \mathbb{R}^n$ 上的函数

- ① 存在 $r > 0$ 使得对于任意 $x \in S \cap B(x^*, r)$ 有 $f(x) \geq f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的局部最小值点
- ② 存在 $r > 0$ 使得对于任意 $x^* \neq x \in S \cap B(x^*, r)$ 有 $f(x) > f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的严格局部最小值点
- ③ 存在 $r > 0$ 使得对于任意 $x \in S \cap B(x^*, r)$ 有 $f(x) \leq f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的局部最大值点
- ④ 存在 $r > 0$ 使得对于任意 $x^* \neq x \in S \cap B(x^*, r)$ 有 $f(x) < f(x^*)$, 则称 $x^* \in S$ 为 f 在 S 上的严格局部最大值点

3. 全局最优与局部最优



注：在数值优化领域，大多数算法设计旨在找到**局部最小值**，而非全局最小值。局部最小值的概念在非线性优化中尤为重要，因为它提供了判断解是否为最优解的一种手段。此外，当优化问题是**凸优化**问题时，局部最小值实际上是全局最小值，这是因为凸函数的性质保证了局部最优解即为全局最优解。

1. Taylor级数

- ① 若一元函数 $f(x)$ 在 $x = x^{(0)}$ 点的某个邻域内具有任意阶导数，则 $f(x)$ 在 $x^{(0)}$ 点的泰勒级数展开式为：

1. Taylor级数

② 二元函数 $f(x_1, x_2)$ 在 $(x_1^{(0)}, x_2^{(0)})$ 点处泰勒级数展开为：

$G(x^{(0)})$ 是 $f(x_1, x_2)$ 在 $(x_1^{(0)}, x_2^{(0)})$ 点处的Hessian(黑塞)矩阵，描述函数局部曲率

1. Taylor级数

③ 多元函数 $f(x_1, x_2, \dots, x_n)$ 在 $(x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})$ 点处泰勒级数展开为：

梯度：

Hessian矩阵：

2. 一阶最优性条件

定理1[局部最优解]: 设 $f: U \rightarrow \mathbb{R}$ 是定义在 $U \subseteq \mathbb{R}^n$ 上的函数, 若 $\mathbf{x}^* \in \text{int}(U)$ 是局部最优解, 并且 f 在 $\mathbf{x}^*$ 处一阶可导, 则 $\nabla f(\mathbf{x}^*) = \mathbf{0}$

定义3 [驻点/稳定点]: 设 $f: U \rightarrow \mathbb{R}$ 是定义在 $U \subseteq \mathbb{R}^n$ 上的函数, f 在 $\mathbf{x}^*$ 一些邻域内可微, 且满足 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 则称 $\mathbf{x}^*$ 为 f 的驻点

3. 二阶必要最优性条件

定理2: 设 $f: U \rightarrow \mathbb{R}$ 是定义在开集 $U \subseteq \mathbb{R}^n$ 上的函数, 在集合 U 上二次连续可微, 且 $\mathbf{x}^*$ 是一个驻点, 即 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 则

- ① 若Hessian矩阵 $\nabla^2 f(\mathbf{x}^*) \succcurlyeq \mathbf{0}$ 半正定, 则 $\mathbf{x}^*$ 是 f 在 U 上的局部最小值点
- ② 若Hessian矩阵 $\nabla^2 f(\mathbf{x}^*) \preccurlyeq \mathbf{0}$ 半负定, 则 $\mathbf{x}^*$ 是 f 在 U 上的局部最大值点

4. 二阶充分最优性条件

定理3: 设 $f: U \rightarrow \mathbb{R}$ 是定义在开集 $U \subseteq \mathbb{R}^n$ 上的函数, 在集合 U 上二次连续可微, 且 $\mathbf{x}^*$ 是一个驻点, 即 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 则

- ① 若Hessian矩阵 $\nabla^2 f(\mathbf{x}^*) > \mathbf{0}$ 正定, 则 $\mathbf{x}^*$ 是 f 在 U 上的严格局部最小值点
- ② 若Hessian矩阵 $\nabla^2 f(\mathbf{x}^*) < \mathbf{0}$ 负定, 则 $\mathbf{x}^*$ 是 f 在 U 上的严格局部最大值点

4. 二阶充分最优性条件

例1: 求三元函数 $f(x, y, z) = x^2 + y^2 + z^2 + 2x + 4y - 6z$ 的极值。


故三元函数的驻点是 $(-1, -2, 3)$ 。

Hessian矩阵为 $A = [2, 0, 0; 0, 2, 0; 0, 0, 2]$ 。因为 A 是正定矩阵 $A > 0$ ，故 $(-1, -2, 3)$ 是极小值点，且极小值为 -14 。

4. 二阶充分最优性条件

定义4[鞍点
连续可微,
鞍点。

定理4[鞍点
合 U 上二次
 U 上的鞍点



合 U 上二次
点, 则称为

函数, 在集
则 x^* 是 f 在

4. 二阶充分最优性条件

例2：确定二元函数的 $f(x_1, x_2) = 2x_1^3 + 3x_2^2 + 3x_1^2x_2 - 24x_2$ 的驻点，极值点与鞍点。

① 计算驻点： $\nabla f(\mathbf{x}) = \begin{bmatrix} 6x_1^2 + 6x_1x_2 \\ 6x_2 + 3x_1^2 - 24 \end{bmatrix} = 0$ ，由此可得驻点为 $(0, 4)$, $(4, -4)$, $(-2, 2)$


② Hessian矩阵： $\nabla^2 f(\mathbf{x}) = 6 \begin{bmatrix} 2x_1 + x_2 & x_1 \\ x_1 & 1 \end{bmatrix}$ ，由此分别判断驻点 $(0, 4)$, $(4, -4)$, $(-2, 2)$ 处Hessian矩阵是否为正定矩阵：

$$\nabla^2 f(0, 4) = 6 \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}, \quad \nabla^2 f(4, -4) = 6 \begin{bmatrix} 4 & 4 \\ 4 & 1 \end{bmatrix}, \quad \nabla^2 f(-2, 2) = 6 \begin{bmatrix} -2 & -2 \\ -2 & 1 \end{bmatrix}$$

5. 全局最优性条件

定理5： 设 f 是定义在 $\mathbb{R}^n$ 上的二次连续可微函数，若对任意 $x^* \in \mathbb{R}^n$ 有 Hessian 矩阵 $\nabla^2 f(x^*) > 0$ 正定，且 x^* 是驻点，则 x^* 是 f 在 U 上的全局最小值点

1. 方法分类



1. 方法分类

- ① **解析法**：利用无约束最优化问题中目标函数 $f(x)$ 的解析表达式和它的解析性质(如函数的一阶导数和二阶导数)，给出一种求它最优解 x^* 的或其近似值的迭代方法。主要包括**梯度法**(Gradient method或称**最速下降法** Steepest descent method)、**共轭梯度法** (Conjugate gradient method)、**非二次函数的共轭梯度法**、**牛顿法**(Newton method)、**拟牛顿法**(Quasi-Newton method) 等。

1. 方法分类

- ② **直接法**：求最优解 x^* 的过程中，只利用函数值，而不涉及函数解析性质。直接法也是一种迭代法，迭代步骤简单，只要求能通过逐步试验最后求得近似最优解。当目标函数 $f(x)$ 表达式复杂，或写不出具体表达式时，它就成了重要的方法。


2. 梯度下降法(Gradient descent method)

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + t_k \mathbf{d}^{(k)}$$

可用一维搜索技术解决

关键是如何确定搜索方向 $\mathbf{d}^{(k)}$

瞎子下山：由于他看不到哪里是山谷，不可能沿直接指向山谷的路线走，他只能在当前位置上，靠手杖作局部探索，哪里最陡就往哪里前进一步，然后在新的位置上再用手杖寻找最陡方向，再下降一步。这就是最速下降法的形象比喻。



最速下降法迭代公式 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - t_k \nabla f(\mathbf{x}^{(k)})$

2. 梯度下降法(Gradient descent method)

泰勒展开：设 f 是 $\mathbb{R}^n$ 上的一次可导，若 $x^{(k)}$ 是函数 f 的极小点的一个近似估计。将函数 f 在 $x^{(k)}$ 处泰勒展开，取一阶近似，则有

$$f(x) \approx f(x_k) + \nabla f(x_k)(x - x_k) + o(\Delta x^2)$$

$$f(x) = f(x_k) + \nabla f(x_k)(x - x_k)$$

$$f(x_{k+1}) = f(x_k) + \nabla f(x_k)(x_{k+1} - x_k)$$

$$f(x_{k+1}) - f(x_k) = \nabla f(x_k)(x_{k+1} - x_k) < 0$$

则 $x_{k+1} - x_k = -\nabla f(x_k)$

2. 梯度下降法(Gradient descent method)

- ① 又称最速下降法，1847年由Cauchy提出
- ② 基本思想：往函数下降最快的方向进行搜索，函数某个方向上的变化率可用函数导数表征，因此搜索方向可由函数导数确定，即以 $f(x)$ 在点 $x^{(k)}$ 方向导数最小的方向作为搜索方向。
- ③ 梯度下降法直观易懂，只需计算目标函数梯度就可写出迭代格式。尽管随着接近目标值，步长 t_k 减小，收敛速度减慢，依然广泛应用，例如神经网络中的后向传导算法(Back Propagation Algorithm)，其中 t_k 则称为学习速度learning rate。

无约束优化方法




大连理工大学
DALIAN UNIVERSITY OF TECHNOLOGY

$$f(x) = x^2$$

Step size: .8

$$x^{(0)} = -4$$




$$f(x) = x^2$$

Step size: .8

$$x^{(0)} = -4$$

$$x^{(1)} = -4 - .8 \cdot 2 \cdot (-4)$$




$$f(x) = x^2$$

Step size: .8

$$x^{(0)} = -4$$

$$x^{(1)} = 2.4$$




$$f(x) = x^2$$

Step size: .8

$$x^{(0)} = -4$$

$$x^{(1)} = 2.4$$

$$x^{(2)} = 2.4 - .8 \cdot 2 \cdot 2.4$$




$$f(x) = x^2$$

Step size: .8

$$x^{(0)} = -4$$

$$x^{(1)} = 2.4$$

$$x^{(2)} = -1.44$$



无约束优化方法



$$f(x) = x^2$$

Step size: .8

$$x^{(0)} = -4$$


$$x^{(1)} = 2.4$$

$$x^{(2)} = -1.44$$

$$x^{(3)} = .864$$

$$x^{(4)} = -0.5184$$


$$x^{(5)} = 0.31104$$



$$x^{(30)} = -8.84296e - 07$$


2. 梯度下降法(Gradient descent method)

定理6: 设从点 $\mathbf{x}_k$ 出发, 沿方向 $\mathbf{d}$ 作精确一维搜索, t_k 为最优步长因子, 即 $f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k + t_k \mathbf{d}_k) = \min_t f(\mathbf{x}_k + t \mathbf{d}_k)$, 则有 $\mathbf{d}_{k+1}^T \mathbf{d}_k = 0$ 。新点处的梯度与搜索方向垂直。



2. 梯度下降法(Gradient descent method)

二维情形下最速下降法搜索路径:



2. 梯度下降法(Gradient descent method)

- ① **最速下降法仅是算法的局部性质。**对许多问题而言，全局看最速下降法并非“最速下降”，而是下降较为缓慢。数值试验表明，当目标函数的等值线接近于一个圆(球)时，最速下降法下降较快；而当目标函数的等值线是一个扁长椭球时，最速下降法开始几步下降较快，后来出现“锯齿”现象，下降较缓。
- ② 相邻两迭代点上函数 $f(x)$ 的两个梯度方向是互相直交，即两个搜索方向互相直交，这就产生了锯齿形状。当接近极小点时，步长愈小，前进愈慢。这就造成了**最优步长的最速下降法**逼近极小点过程是“之”字形，并且越靠近极小点步长越小，移动越慢，以至在实际运用中在可行的计算时间内得不到需要的结果。

2. 梯度下降法(Gradient descent method)

例：用最速下降法求函数 $f(x_1, x_2) = x_1^2 + 4x_2^2$ 的极小点，初始点取为 $\mathbf{x}^0 = [1, 1]^T$ 。

① 梯度 $\nabla f(x_1, x_2) = [2x_1 \quad 8x_2]^T$

② 第一次迭代： $\nabla f(x_1^0, x_2^0) = [2 \quad 8]^T$

$$\mathbf{x}^1 = \mathbf{x}^0 - t_0 \nabla f(x_1^0, x_2^0)$$

$$\mathbf{x}^1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - t_0 \begin{bmatrix} 2 \\ 8 \end{bmatrix}$$

$$f(\mathbf{x}^1) = (1 - 2t_0)^2 + 4(1 - 8t_0)^2 = 5 - 68t_0 + 260t_0^2$$

$$\frac{\partial f(\mathbf{x}^1)}{\partial t_0} = 0 \Rightarrow 520t_0 - 68 = 0 \Rightarrow t_0 = \frac{68}{520} = 0.131$$

2. 梯度下降法(Gradient descent method)

作业1: 用最速下降法求函数 $f(x_1, x_2) = 10x_1^2 + x_2^2$ 极小点, 初始点 $x^0 = [1, 1]^T$ 。

3. 牛顿法(Newton method, 二阶方法)

- ① **问题：**由最速下降法可知，从全局角度看，负梯度方向一般不是一个特别好的方向，有没有更好的方向？

3. 牛顿法(Newton method, 二阶方法)

② 基本原理：设 f 是 $\mathbb{R}^n$ 上的二次连续可微函数，若 $x^{(k)}$ 是函数 f 的极小点的一个近似估计。将函数 f 在 $x^{(k)}$ 处泰勒展开，取二阶近似，则有：

$$f(x) \approx f(x_k) + \nabla f(x_k)(x - x_k) + \frac{\nabla^2 f(x_k)}{2!}(x - x_k)^2 + o(\Delta x^3)$$



$$f(x) \approx f(x_k) + \nabla f(x_k)(x - x_k) + \frac{\nabla^2 f(x_k)}{2!}(x - x_k)^2$$

$$f(x_{k+1}) \approx f(x_k) + \nabla f(x_k)(x_{k+1} - x_k) + \frac{\nabla^2 f(x_k)}{2!}(x_{k+1} - x_k)^2$$

$$f(x_{k+1}) - f(x_k) = \nabla f(x_k)\Delta x + \frac{\nabla^2 f(x_k)}{2!}(\Delta x)^2$$

$$\nabla f(x_k) + \nabla^2 f(x_k)\Delta x = 0$$

3. 牛顿法(Newton method, 二阶方法)



3. 牛顿法(Newton method, 二阶方法)

- ① **问题：**由最速下降法可知，从全局角度看，负梯度方向一般不是一个特别好的方向，有没有更好的方向？
- ② **基本原理：**设 f 是 $\mathbb{R}^n$ 上的二次连续可微函数，若 $x^{(k)}$ 是函数 f 的极小点的一个近似估计。将函数 f 在 $x^{(k)}$ 处泰勒展开，取二阶近似，则有：

$$f(x) = f(x^{(k)}) + \nabla f(x^{(k)})^T \Delta x + \frac{1}{2} \Delta x^T \nabla^2 f(x^{(k)}) \Delta x + o(\Delta x^3) \approx f(\Delta x; x^{(k)})$$

取 $f(\Delta x; x^{(k)})$ 的平稳点作为 $f(x)$ 最优点的一个近似点

$$\text{令 } \nabla f(\Delta x; x^{(k)}) = \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) \Delta x = 0$$

设函数 $f(x)$ 的 Hessian 矩阵可逆，由上式可得：

$f(x)$ 在 $x^{(k)}$ 处的
二次近似函数

3. 牛顿法(Newton method, 二阶方法)


$$\mathbf{x} - \mathbf{x}^{(k)} = \Delta \mathbf{x} = -\nabla^2 f(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)})$$

Newton法迭代公式:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \nabla^2 f(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)})$$

或 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \mathbf{H}(\mathbf{x}^{(k)})^{-1} \mathbf{g}(\mathbf{x}^{(k)})$

这样, 知道 $\mathbf{x}^{(k)}$ 后, 算出在这一点处目标函数的梯度和Hessian矩阵的逆, 代入便得到后继点 $\mathbf{x}^{(k+1)}$ 。



3. 牛顿法(Newton method, 二阶方法)

- ① 牛顿法利用迭代点 $x^{(k)}$ 处的一阶导数(梯度)和二阶导数(Hessian矩阵)对目标函数进行二次近似, 然后将该近似模型的极小点作为新的迭代点, 并不断重复该过程直至求得满足精度要求的近似极小值。
- ② 当 $f(x)$ 是单变量函数时, Newton法即为一维搜索的Newton法
- ③ 当 $f(x)$ 是二次函数时, 一次迭代就可达到平稳点

3. 牛顿法(Newton method, 二阶方法)

例题：用Newton法求函数 $f(x_1, x_2) = 8x_1^2 + 4x_1x_2 + 5x_2^2$ 的极小点，初始点 $\mathbf{x}_0 = [10, 10]^T$ 。

解： $\nabla f(\mathbf{x}) = [16x_1 + 4x_2, 4x_1 + 10x_2]^T$

$$\nabla^2 f(\mathbf{x}) = \mathbf{H}(\mathbf{x}) = \begin{pmatrix} 16 & 4 \\ 4 & 10 \end{pmatrix}$$

$$\mathbf{H}(\mathbf{x})^{-1} = \frac{1}{144} \begin{pmatrix} 10 & -4 \\ -4 & 16 \end{pmatrix}$$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} - \mathbf{H}(\mathbf{x}^{(0)})^{-1} \nabla f(\mathbf{x}^{(0)})$$

$$= \begin{pmatrix} 10 \\ 10 \end{pmatrix} - \frac{1}{144} \begin{pmatrix} 10 & -4 \\ -4 & 16 \end{pmatrix} \begin{pmatrix} 200 \\ 140 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

因为 $f(\mathbf{x})$ 是二次函数，所以一步迭代就达到平稳点，又因为 $\mathbf{H}(\mathbf{x}^{(1)})$ 是正定矩阵，所以 $\mathbf{x}^{(1)}$ 是极小点。

3. 牛顿法(Newton method, 二阶方法)

局部收敛性：设目标函数 $f(x)$ 在其局部极小点 x^* 的一个邻域 D 内二阶连续可微，其Hessian矩阵 $\nabla^2 f(x)$ 在 D 内满足**Lipschitz条件**：存在 $\beta > 0$ ，使得：

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq \beta \|x - y\|_2 \quad \forall x, y \in D$$

若 $\nabla^2 f(x) > 0$ **Hessian矩阵正定**，那么当 x_0 充分接近 x^* 时，则Newton迭代所得点列至少依二阶收敛于 x^* 。

3. 牛顿法(Newton method, 二阶方法)

- ① 初始点选择恰当, 则Newton法收敛很快, 具有二阶收敛速度。对初始点要求高, 一般要求初始点离极小点较近, 否则不收敛。有时即使是收敛的, 但因初始点离极大点或鞍点较近, 会收敛于极大点或鞍点。
- ② Newton法要求Hessian矩阵可逆。若Hessian矩阵正定, 则Hessian矩阵可逆, 算法可行, 并证所得平稳点为极小点。然而迭代过程中Hessian矩阵并不总能保持正定。除非二次函数, 搜索方向 $[\nabla^2 f(\mathbf{x})]^{-1}[\nabla f(\mathbf{x})]$ 不一定是下降方向。
- ③ 每一步迭代都需要求解一个n维线性方程组, 这导致高维问题中计算量很大。海塞矩阵不容易计算且不容易存储。

3. 牛顿法(LM修正)

- ① 若Hessian矩阵非正定 $\nabla^2 f(\mathbf{x}) \leq 0$ 导致搜索方向 $[\nabla^2 f(\mathbf{x})]^{-1}[\nabla f(\mathbf{x})]$ 可能不是下降方向，LM修正可解决该问题，确保每次迭代产生的方向是下降的，修正之后的迭代公式为：

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [\nabla^2 f(\mathbf{x}) + \mu \mathbf{I}]^{-1} [\nabla f(\mathbf{x})]$$

其中， $\mu \geq 0$ ， $\mathbf{I}$ = 单位矩阵。

- ② 若 μ 值较大， $\mu \mathbf{I}$ 占主导，接近一阶梯度下降法，距最优点尚远；若 μ 值较小， $\nabla^2 f(\mathbf{x})$ 占主导，距最优点较近。因此， μ 值不仅影响迭代方向还影响迭代步长。

3. 牛顿法(Newton method, 二阶方法)


作业2: 用Newton法求函数 $f(x_1, x_2) = x_1^2 + 25x_2^2$ 的极小点, 初始点 $x_0 = [2, 2]^T$.

4. 共轭梯度法(Conjugate gradient method)

- ① 最速下降法，计算步骤简单，开始几步收敛较快，但往后收敛速度越来越慢；在最优解的附近，牛顿法以及修正牛顿法收敛速度快，但需要计算Hessian矩阵及其逆矩阵，计算量和存储量都很大。
- ② 有没有一种算法？它的收敛速度介于最速下降法与牛顿法之间，兼具牛顿法收敛速度快与最速下降法计算简单的优点，无需计算Hessian矩阵的逆矩阵，对二次函数只需有限次迭代就能达到最优解。
- ③ 共轭梯度法即为其中一种，利用梯度生成共轭方向。


4. 共轭梯度法(Conjugate gradient method)

- ① 共轭方向：如图所示， AB ， CD 过椭圆的中心， CD 平行于椭圆上在点 A ， B 的切线，在几何上称 AB 与 CD 为共轭直径。 AB 与 CD 的方向称为共轭方向。



4. 共轭梯度法(Conjugate gradient method)

- ① 可用上述椭圆(或 n 维椭球)的共轭性质来获得较快的收敛速度。当 $n=2$ 时, 若在椭圆上两点 A, B 的切线平行, 则直线 AB 必过椭圆中心。在点 A, B 的切线方向与 AB 的方向称为共轭方向。这种共轭关系如何表示呢? 有如下定理:
- ② 设 $f(x)=1/2x^TAx+b^Tx+c$, $A^T=A>0$, 给定方向 p_1 , 在与 p_1 平行的两条直线上(如图), $f(x)$ 的最小点为 x^1, x^2 , 则 $p_1^TAp_2=0$, $p_2=x^2-x^1$



注: 该示意图说明沿任意 p_1 得到极小点后, 沿其共轭方向 p_2 必找到二维问题的极小点!

4. 共轭梯度法(Conjugate gradient method)

共轭： 设 A 是 $n \times n$ 阶对称正定矩阵

- ① x, y 为两个 n 维向量, 若 $x^T A y = 0$, 则称 x 与 y 为 A 共轭或 A 正交, 这两向量的方向为 A 共轭方向
- ② 若 A 为单位矩阵, 则 $x^T y = 0$, 即 x 与 y 是正交的。



“共轭”是“正交”概念的推广

4. 共轭梯度法(Conjugate gradient method)

- ① 基本原理：利用目标函数的梯度逐步产生共轭方向，并将其作为搜索方向。这些共轭方向在某种内积下正交，通过当前点处的负梯度与上次迭代的搜索方向组合来构造。迭代过程中，算法沿当前搜索方向进行一维搜索，找到最优步长并更新解，然后构造下一个搜索方向，直到满足收敛条件。
- ② 共轭梯度法收敛速度快、存储量小、计算成本低和稳定性高，广泛应用于线性方程组求解、无约束优化问题以及偏微分方程数值解法等领域。
- ③ 算法步骤包括选择初始点和搜索方向，进行一维搜索并更新解，计算新梯度和构造新搜索方向，重复这些步骤直到收敛。

4. 共轭梯度法(Conjugate gradient method)

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c, \mathbf{A} > 0$$

计算原理:

- ① 从初始点 $\mathbf{x}^0$ 出发沿梯度反方向 $-\nabla f(\mathbf{x}^0)$ 搜索: $\mathbf{p}^0 = -\nabla f(\mathbf{x}^0)$, $\mathbf{x}^1 = \mathbf{x}^0 + \lambda_1 \mathbf{p}^0$
- ② 若 $\nabla f(\mathbf{x}^1) = 0$, 停止; 否则由 $-\nabla f(\mathbf{x}^1)$ 和 $\mathbf{p}^0$ 构建向量 $\mathbf{p}^1 = -\nabla f(\mathbf{x}^1) + \alpha_0 \mathbf{p}^0$, 使 $[\mathbf{p}^1]^T \mathbf{A} \mathbf{p}^0 = 0 \Rightarrow [-\nabla f(\mathbf{x}^1) + \alpha_0 \mathbf{p}^0]^T \mathbf{A} \mathbf{p}^0 = 0$

$$\alpha_0 = \frac{[\nabla f(\mathbf{x}^1)]^T \mathbf{A} \mathbf{p}^0}{[\mathbf{p}^0]^T \mathbf{A} \mathbf{p}^0}$$

- ③ 在 $\mathbf{x}^1$ 处沿 $\mathbf{p}^1$ 方向搜索 $\mathbf{x}^2 = \mathbf{x}^1 + \lambda_2 \mathbf{p}^1$

4. 共轭梯度法(Conjugate gradient method)

- ④ 若 $\nabla f(\mathbf{x}^2) = 0$, 停止; 否则由 $-\nabla f(\mathbf{x}^2)$ 和 $\mathbf{p}^1$ 构建向量 $\mathbf{p}^2 = -\nabla f(\mathbf{x}^2) + \alpha_1 \mathbf{p}^1$, 使 $[\mathbf{p}^2]^T \mathbf{A} \mathbf{p}^1 = 0 \Rightarrow [-\nabla f(\mathbf{x}^2) + \alpha_1 \mathbf{p}^1]^T \mathbf{A} \mathbf{p}^1 = 0$

$$\alpha_1 = \frac{[\nabla f(\mathbf{x}^2)]^T \mathbf{A} \mathbf{p}^1}{[\mathbf{p}^1]^T \mathbf{A} \mathbf{p}^1}$$

- ⑤ 重复上述步骤, 若 $\nabla f(\mathbf{x}^{k+1}) = 0$, 则停止; 否则 $-\nabla f(\mathbf{x}^{k+1})$ 和 $\mathbf{p}^k$ 构建向量 $\mathbf{p}^{k+1} = -\nabla f(\mathbf{x}^{k+1}) + \alpha_k \mathbf{p}^k$, 使 $[\mathbf{p}^{k+1}]^T \mathbf{A} \mathbf{p}^k = 0 \Rightarrow [-\nabla f(\mathbf{x}^{k+1}) + \alpha_k \mathbf{p}^k]^T \mathbf{A} \mathbf{p}^k = 0$

$$\alpha_k = \frac{[\nabla f(\mathbf{x}^{k+1})]^T \mathbf{A} \mathbf{p}^k}{[\mathbf{p}^k]^T \mathbf{A} \mathbf{p}^k}$$

- ⑥ 由此构造了一组向量组 $\mathbf{p}^0, \mathbf{p}^1, \mathbf{p}^2, \dots, \mathbf{p}^n$ 为 $\mathbf{A}$ 的共轭向量组

4. 共轭梯度法(Conjugate gradient method)

- ① **定理1:** 设 $p_1, p_2, \dots, p_m$ 是由上述方法产生的向量组, 而 $g_1, g_2, \dots, g_n$ 是由各点梯度生成的向量组, $g_k = \nabla f(x^k)$, 则 $p_1, p_2, \dots, p_m$ 是正交向量组; $g_1, g_2, \dots, g_n$ 是 A 的共轭向量组。
- ② **定理2:** 若 A 是 $n \times n$ 阶对称正定矩阵, $p_1, p_2, \dots, p_m$ 是由上述方法构造的 A 的共轭向量组, $g_k = \nabla f(x^k)$, 则以下计算公式等价:

Daniel共轭梯度法:
$$\alpha_k = \frac{[g_{k+1}]^T A p^k}{[p^k]^T A p^k}$$

SW共轭梯度法:
$$\alpha_k = \frac{[g_{k+1}]^T (g_{k+1} - g_k)}{[p^k]^T (g_{k+1} - g_k)}$$

DM共轭梯度法:
$$\alpha_k = \frac{[g_{k+1}]^T g_{k+1}}{[p^k]^T g_k}$$

FR共轭梯度法:
$$\alpha_k = \frac{\|g_{k+1}\|^2}{\|g_k\|^2}$$

FPR共轭梯度法:
$$\alpha_k = \frac{[g_{k+1}]^T (g_{k+1} - g_k)}{[g_k]^T g_k}$$

4. 共轭梯度法(Conjugate gradient method)

计算步骤:

- ① 选定初始点 x^0
- ② 若 $\|g_1\| \leq \varepsilon$, 算法停止, $x^* = x^0$, 否则转步骤3
- ③ 取 $p^1 = -g_1$, $k = 1$
- ④ 精确一维搜索找最佳步长 λ_k , 令 $x^{k+1} = x^k + \lambda_k p^k$
- ⑤ 若 $\|g_{k+1}\| \leq \varepsilon$, 算法停止, $x^* = x^{k+1}$, 否则转步骤6
- ⑥ 若 $k = n$, 令 $x^0 = x^{k+1}$, $p^1 = -g_{k+1}$, $k = 1$, 转步骤4; 否则转步骤7
- ⑦ 计算 $\alpha_k = \frac{\|g_{k+1}\|^2}{\|g_k\|^2}$, $p^{k+1} = -g_{k+1} + \alpha_k p^k$, 转步骤4

4. 共轭梯度法(Conjugate gradient method)

例：用FR共轭梯度法求函数 $f(\mathbf{x}) = x_1^2 + 2x_2^2 - 4x_1 - 2x_1x_2$ 的极小点，初始点 $(1, 1)^T$ ，迭代精度 $\varepsilon = 0.001$ 。

解：

① 第一次迭代：沿负梯度方向搜索

$$\mathbf{g}_1 = \nabla f(\mathbf{x}^1) = \begin{bmatrix} 2x_1 - 4 - 2x_2 \\ 4x_2 - 2x_1 \end{bmatrix} = \begin{bmatrix} -4 \\ 2 \end{bmatrix}, \quad \mathbf{p}^1 = -\mathbf{g}_1 = \begin{bmatrix} 4 \\ -2 \end{bmatrix}$$

$$\mathbf{x}^2 = \mathbf{x}^1 + \lambda \mathbf{p}^1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda \begin{bmatrix} 4 \\ -2 \end{bmatrix} = \begin{bmatrix} 1 + 4\lambda \\ 1 - 2\lambda \end{bmatrix}$$

$$\varphi(\lambda) = (1 + 4\lambda)^2 + 2(1 - 2\lambda)^2 - 4(1 + 4\lambda) - 2(1 + 4\lambda)(1 - 2\lambda)$$

$$\frac{\partial \varphi(\lambda)}{\partial \lambda} = 80\lambda - 20 = 0 \Rightarrow \lambda = \frac{1}{4}$$

4. 共轭梯度法(Conjugate gradient method)

例：用FR共轭梯度法求函数 $f(\mathbf{x}) = x_1^2 + 2x_2^2 - 4x_1 - 2x_1x_2$ 的极小点，初始点 $(1, 1)^T$ ，迭代精度 $\varepsilon = 0.001$ 。

解：

① 第一次迭代：沿负梯度方向搜索

$$\mathbf{x}^2 = \begin{bmatrix} 2 \\ 0.5 \end{bmatrix}, \quad \mathbf{g}_2 = \nabla f(\mathbf{x}^2) = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

不满足要求，继续迭代。

② 第二次迭代：沿负梯度方向搜索

$$\alpha_1 = \frac{\|\mathbf{g}_2\|^2}{\|\mathbf{g}_1\|^2} = \frac{1}{4}, \quad \mathbf{p}^2 = -\mathbf{g}_2 + \alpha_1 \mathbf{p}^1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \frac{1}{4} \begin{bmatrix} 4 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ 1.5 \end{bmatrix}$$

4. 共轭梯度法(Conjugate gradient method)

例：用FR共轭梯度法求函数 $f(\mathbf{x}) = x_1^2 + 2x_2^2 - 4x_1 - 2x_1x_2$ 的极小点，初始点 $(1, 1)^T$ ，迭代精度 $\varepsilon = 0.001$ 。

解：

② 第二次迭代：沿负梯度方向搜索

$$\alpha_1 = \frac{\|g_2\|^2}{\|g_1\|^2} = \frac{1}{4}, \quad p^2 = -g_2 + \alpha_1 p^1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \frac{1}{4} \begin{bmatrix} 4 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ 1.5 \end{bmatrix}$$

$$\mathbf{x}^3 = \mathbf{x}^2 + \lambda p^2 = \begin{bmatrix} 2 \\ 0.5 \end{bmatrix} + \lambda \begin{bmatrix} 2 \\ 1.5 \end{bmatrix} = \begin{bmatrix} 2 + 2\lambda \\ 0.5 + 1.5\lambda \end{bmatrix}$$

$$\varphi(\lambda) = (2 + 2\lambda)^2 + 2(0.5 + 1.5\lambda)^2 - 4(2 + 2\lambda) - 2(2 + 2\lambda)(0.5 + 1.5\lambda)$$

$$\frac{\partial \varphi(\lambda)}{\partial \lambda} = 0 \Rightarrow \lambda = 1$$

4. 共轭梯度法(Conjugate gradient method)

例：用FR共轭梯度法求函数 $f(\mathbf{x}) = x_1^2 + 2x_2^2 - 4x_1 - 2x_1x_2$ 的极小点，初始点 $(1, 1)^T$ ，迭代精度 $\varepsilon = 0.001$ 。

解：


② 第二次迭代：沿负梯度方向搜索

$$\mathbf{x}^3 = \mathbf{x}^2 + \lambda \mathbf{p}^2 = \begin{bmatrix} 2 + 2\lambda \\ 0.5 + 1.5\lambda \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$


$$\mathbf{g}_3 = \nabla f(\mathbf{x}^3) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

满足精度要求，得最优解 $\mathbf{x}^* = \mathbf{x}^3 = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$

4. 共轭梯度法(Conjugate gradient method)



4. 共轭梯度法(Conjugate gradient method)



4. 共轭梯度法(Conjugate gradient method)

作业3: 用FR共轭梯度法求函数 $f(\mathbf{x}) = x_1^2 + 2x_2^2$ 极小点, 初始点 $(5, 5)^T$ 。

5. 拟牛顿法(Quasi-Newton method)

① **基本思想**：不计算目标函数 $f(\mathbf{x})$ 的Hessian矩阵 $\nabla^2 f(\mathbf{x})$ ，而是构造一个近似Hessian矩阵的对称正定矩阵；根据该近似矩阵来优化目标函数，不同的构造近似Hessian矩阵的方法决定了不同的**拟牛顿法**，降低了计算量。

a. 将函数二阶连续可微函数 $f(\mathbf{x})$ 在 $\mathbf{x}_{k+1}$ 处二阶泰勒展开：

$$f(\mathbf{x}) = f(\mathbf{x}_{k+1}) + \nabla f(\mathbf{x}_{k+1})^T (\mathbf{x} - \mathbf{x}_{k+1}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_{k+1})^T \nabla^2 f(\mathbf{x}_{k+1}) (\mathbf{x} - \mathbf{x}_{k+1})$$

b. 上式对 $\mathbf{x}_{k+1}$ 求导可得

$$\nabla f(\mathbf{x}) = \nabla f(\mathbf{x}_{k+1}) + \nabla^2 f(\mathbf{x}_{k+1}) (\mathbf{x} - \mathbf{x}_{k+1})$$

c. 令 $\mathbf{g} = \nabla f(\mathbf{x})$ ， $\mathbf{g}_{k+1} = \nabla f(\mathbf{x}_{k+1})$ ， $\mathbf{H}_{k+1} = \nabla^2 f(\mathbf{x}_{k+1})$ 则有

$$\mathbf{g} = \mathbf{g}_{k+1} + \mathbf{H}_{k+1} (\mathbf{x} - \mathbf{x}_{k+1})$$

5. 拟牛顿法(Quasi-Newton method)

- ① **基本思想**：不计算目标函数 $f(x)$ Hessian矩阵 $\nabla^2 f(x)$ ，而是构造一个近似Hessian矩阵的对称正定矩阵；根据该近似矩阵来优化目标函数，不同的构造近似Hessian矩阵的方法决定了不同的**拟牛顿法**，降低了计算量。

d. 令 $x = x_k$ ，整理可得：


$$g_{k+1} - g_k = H_{k+1}(x_{k+1} - x_k)$$

迭代过程中对 H_{k+1} 做出约束，根据约束构造一个近似矩阵 B_{k+1} 模拟Hessian矩阵。令 $y_k = g_{k+1} - g_k$ ， $s_k = x_{k+1} - x_k$ ，由此可得拟牛顿条件：

$$y_k = B_{k+1}s_k$$

保证 x_k 与 x_{k+1} 满足梯度的割线方程

5. 拟牛顿法(Quasi-Newton method)



5. 拟牛顿法(Quasi-Newton method)

② BFGS(Broyden, Fletcher, Goldfarb, and Shanno)基本原理: 通过迭代构建目标函数 $f(x)$ 的近似Hessian矩阵 $\nabla^2 f(x) \succ 0$ 。首先初始化 $B_0 = I$, 由 $B_{k+1} = B_k + \Delta B_k$ 迭代更新矩阵 B_{k+1} , 其中

$$\Delta B_k = \alpha u u^T + \beta v v^T$$

其中 u 和 v 待定。

$$y_k = B_{k+1} s_k = B_k s_k + (\alpha u^T s_k) u + (\beta v^T s_k) v$$

做如下赋值运算:

$$\alpha u^T s_k = 1, \quad \beta v^T s_k = -1$$

$$y_k - B_k s_k = u - v$$

$$y_k = u, \quad B_k s_k = v$$

$$\alpha = \frac{1}{y_k^T s_k}, \quad \beta = \frac{-1}{[B_k s_k]^T s_k} = \frac{-1}{s_k^T B_k s_k}$$

5. 拟牛顿法(Quasi-Newton method)

- ② BFGS(Broyden, Fletcher, Goldfarb, and Shanno)基本原理：通过迭代构建目标函数 $f(\mathbf{x})$ 的近似Hessian矩阵 $\nabla^2 f(\mathbf{x}) \succ 0$ 。首先初始化 $\mathbf{B}_0 = \mathbf{I}$ ，由 $\mathbf{B}_{k+1} = \mathbf{B}_k + \Delta \mathbf{B}_k$ 迭代更新矩阵 $\mathbf{B}_{k+1}$ ，其中

$$\Delta \mathbf{B}_k = \alpha \mathbf{u} \mathbf{u}^T + \beta \mathbf{v} \mathbf{v}^T$$

做如下赋值运算：

$$\Delta \mathbf{B}_k = \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k}$$

$$\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k}$$

5. 拟牛顿法(Quasi-Newton method)

③ BFGS(Broyden, Fletcher, Goldfarb, and Shanno)计算流程:

- 给定初始值 $\mathbf{x}_0$, 收敛准则 $\varepsilon > 0$, $\mathbf{B}_0 = \mathbf{I}$, $k = 0$
- 基于目标函数梯度 $\nabla f(\mathbf{x})$ 计算搜索方向: $\mathbf{d}_k = \mathbf{B}_k^{-1} \nabla f(\mathbf{x}_k)$
- 计算迭代步长 λ_k , 令 $\mathbf{s}_k = \lambda_k \mathbf{d}_k$, $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{s}_k$
- 若 $\|\nabla f(\mathbf{x}_{k+1})\| < \varepsilon$, 停止迭代, 否则转至步骤5
- 计算 $\mathbf{y}_k = \nabla f(\mathbf{x}_{k+1}) - \nabla f(\mathbf{x}_k)$
- 计算近似矩阵 $\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k}$
- 令 $k = k + 1$, 转至步骤2

5. 拟牛顿法(Quasi-Newton method)

例：用拟牛顿法求函数 $f(\mathbf{x}) = x_1^2 + \frac{1}{2}x_2^2 + 3$ 极小点，初始点 $(1, 2)^T$ 。

解：

a. $\mathbf{B}_0 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, $\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ x_2 \end{bmatrix}$, $\varepsilon = 10^{-5}$, $k = 0$, $\lambda = 1$

b. $\mathbf{d}_0 = -\mathbf{B}_0^{-1}\nabla f(\mathbf{x}_0) = -\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} -2 \\ -2 \end{bmatrix}$

c. 令 $\mathbf{s}_0 = \mathbf{d}_0 = \begin{bmatrix} -2 \\ -2 \end{bmatrix}$, $\mathbf{x}_1 = \mathbf{x}_0 + \mathbf{s}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} -2 \\ -2 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$

d. 计算 $\nabla f(\mathbf{x}_1) = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$, 不满足迭代收敛条件

e. 计算 $\mathbf{y}_0 = \nabla f(\mathbf{x}_1) - \nabla f(\mathbf{x}_0) = \begin{bmatrix} -2 \\ 0 \end{bmatrix} - \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$

5. 拟牛顿法(Quasi-Newton method)

例：用拟牛顿法求函数 $f(\mathbf{x}) = x_1^2 + \frac{1}{2}x_2^2 + 3$ 极小点，初始点 $(1, 2)^T$ 。

解：

f. 计算近似矩阵
$$\mathbf{B}_1 = \mathbf{B}_0 + \frac{y_0 y_0^T}{y_0^T s_0} - \frac{\mathbf{B}_0 s_0 s_0^T \mathbf{B}_0}{s_0^T \mathbf{B}_0 s_0}$$

5. 拟牛顿法(Quasi-Newton method)

例：用拟牛顿法求函数 $f(x) = x_1^2 - 2x_1x_2 + 4x_2^2$ 极小点，初始点 $(-3, 2)^T$ 。

